

Bootcamp Data Science

Statystyka

Przemysław Spurek

Definicja

Prostą próbą losową (lub krócej próbą losową) o licznosci n nazywamy ciąg niezależnych zmiennych losowych X_1, X_2, \dots, X_n określonych na przestrzeni zdarzeń elementarnych Ω i takich, że każda ze zmiennych ma taki sam rozkład.

Definicja

Statystyką nazywamy każdą zmienną losową będącą ustaloną funkcją próby losowej X_1, X_2, \dots, X_n .

Definicja

Każdą statystykę, którą przyjmujemy jako oszacowanie (przybliżenie) nieznanego parametru rozkładu będziemy nazywać *estymatorem*.

Uwaga

Statystyką jest więc, na przykład, najmniejsza, największa wartość w próbie, iloczyn lub suma kwadratów wszystkich wartości. Oczywiście, wybór konkretnej statystyki związany jest z nieznaną wielkością (parametrem) charakteryzującą populację, którą chcemy szacować. Statystykę

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i$$

nazywamy średnią z próby losowej X_1, X_2, \dots, X_n .

Uwaga

Statystyką jest więc, na przykład, najmniejsza, największa wartość w próbie, iloczyn lub suma kwadratów wszystkich wartości. Oczywiście, wybór konkretnej statystyki związany jest z nieznaną wielkością (parametrem) charakteryzującą populację, którą chcemy szacować. Statystykę

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i$$

nazywamy średnią z próby losowej X_1, X_2, \dots, X_n .

Definicja

Każdą statystykę, którą przyjmujemy jako oszacowanie (przybliżenie) nieznanego parametru rozkładu nazywamy *estymatorem*.

Jednym z zadań statystyki jest znajdowanie estymatorów (a więc statystyk), które w jakimś sensie mówią nam o rozkładzie zmiennej losowej X , z której pochodzi dana próbka. Na przykład, wydaje się, że znajomość średniej arytmetycznej:

$$\bar{X} = \frac{X_1 + \dots + X_n}{n},$$

daje nam pewne informacje o nadziei matematycznej $\mathbb{E}(X)$.

Zauważmy jednak, że istnieją inne estymatory, które także dają pewne informacje o wartości średniej - przykładowo:

$$T(x_1, \dots, x_n) = \frac{x_1 + x_n}{2}$$

lub

$$T(x_1, \dots, x_n) = \frac{\min_{1 \leq i \leq n} \{x_i\} + \max_{1 \leq i \leq n} \{x_i\}}{2}.$$

Oczywiście, można wskazać jeszcze inne, dość “rozsądne” estymatory nadziei matematycznej.

Zauważmy jednak, że istnieją inne estymatory, które także dają pewne informacje o wartości średniej - przykładowo:

$$T(x_1, \dots, x_n) = \frac{x_1 + x_n}{2}$$

lub

$$T(x_1, \dots, x_n) = \frac{\min_{1 \leq i \leq n} \{x_i\} + \max_{1 \leq i \leq n} \{x_i\}}{2}.$$

Oczywiście, można wskazać jeszcze inne, dość “rozsądne” estymatory nadziei matematycznej.

Powstaje więc problem, jaki estymator należy stosować w konkretnej sytuacji?

Zauważmy jednak, że istnieją inne estymatory, które także dają pewne informacje o wartości średniej - przykładowo:

$$T(x_1, \dots, x_n) = \frac{x_1 + x_n}{2}$$

lub

$$T(x_1, \dots, x_n) = \frac{\min_{1 \leq i \leq n} \{x_i\} + \max_{1 \leq i \leq n} \{x_i\}}{2}.$$

Oczywiście, można wskazać jeszcze inne, dość “rozsądne” estymatory nadziei matematycznej.

Powstaje więc problem, jaki estymator należy stosować w konkretnej sytuacji?

Rozwiązuje się go w ten sposób, że wprowadza się kilka kryteriów, które powinien spełniać “dobry” estymator, a następnie bada się, czy rozpatrywany przez nas estymator spełnia te kryteria.

Definicja

Estymator $\hat{\Theta}_n$ parametru Θ będziemy nazywać **nieobciążonym** jeżeli (dla wszystkich n)

$$E(\hat{\Theta}_n) = \Theta.$$

Zadanie

Czy średnia z próby X_1, \dots, X_n jest nieobciążonym estymatorem parametru średniej $E(X)$?

Oznaczmy

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Zadanie

Czy średnia z próby X_1, \dots, X_n jest nieobciążonym estymatorem parametru średniej $E(X)$?

Oznaczmy

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Mamy pokazać, że

$$E(\bar{X}) = E(X).$$

Zadanie

Czy średnia z próby X_1, \dots, X_n jest nieobciążonym estymatorem parametru średniej $E(X)$?

Oznaczmy

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Mamy pokazać, że

$$E(\bar{X}) = E(X).$$

Czyli

$$E(\bar{X}) = E\left(\frac{X_1 + \dots + X_n}{n}\right) = \frac{1}{n}E(X_1 + \dots + X_n) = \frac{1}{n}nE(X) = E(X).$$

Zadanie

Niech X_1, \dots, X_n będzie próbą prostą pobraną z populacji, w której cecha X ma skończoną i różną od zera wartość σ^2 , gdy wartość oczekiwana jest znana $E(X) = m$. Pokaż, że wariancja empiryczna $S_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2$ jest estymatorem nieobciążonym nieznanej wariancji σ^2 .

Zadanie

Niech X_1, \dots, X_n będzie próbą prostą pobraną z populacji, w której cecha X ma skończoną i różną od zera wartość σ^2 , gdy wartość oczekiwana jest znana $E(X) = m$. Pokaż, że wariancja empiryczna $S_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2$ jest estymatorem nieobciążonym nieznanej wariancji σ^2 .

Mamy pokazać, że:

$$E(S_1^2(X_1, \dots, X_n)) = D^2(X).$$

Zadanie

Niech X_1, \dots, X_n będzie próbą prostą pobraną z populacji, w której cecha X ma skończoną i różną od zera wartość σ^2 , gdy wartość oczekiwana jest znana $E(X) = m$. Pokaż, że wariancja empiryczna $S_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2$ jest estymatorem nieobciążonym nieznanej wariancji σ^2 .

Mamy pokazać, że:

$$E(S_1^2(X_1, \dots, X_n)) = D^2(X).$$

Czyli

$$\begin{aligned} E(S_1^2(X_1, \dots, X_n)) &= E\left(\frac{1}{n} \sum_{i=1}^n (X_i - m)^2\right) = \\ &= \frac{1}{n} \sum_{i=1}^n E((X_i - m)^2) = \frac{1}{n} n D^2(X) = D^2(X). \end{aligned}$$

Zadanie*

W przypadku, gdy nie znamy nadziei matematycznej m , możemy także estymować wariancję - definiujemy wtedy S^2 następująco:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, \text{ gdzie } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Pokazać, że jest to estymator obciążony oraz zachodzi wzór:

$$E(S^2(X_1, \dots, X_n)) = \frac{n-1}{n} D^2(X).$$

Zadanie*

Wykorzystując wynik z powyższego zadania pokaż, że:

$$S^{2*} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \text{ gdzie } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

jest estymatorem nieobciążonym nieznanej wariancji σ^2 .

Zrozumiałym jest też, że wymagamy, aby ze wzrostem liczności próbki wzrastała dokładność oszacowanego parametru Θ .

Zrozumieliśmy już też, że wymagamy, aby ze wzrostem liczności próbki wzrastała dokładność oszacowanego parametru Θ .

Wymaganie to prowadzi do spełnienia (dla każdej liczby $\epsilon > 0$) warunku:

$$\lim_{n \rightarrow \infty} P(|\hat{\Theta}_n - \Theta| < \epsilon) = 1.$$

oznaczającego zbieżność w sensie prawdopodobieństwa (zbieżność stochastyczną) Θ_n do Θ .

Zrozumieliśmy już też, że wymagamy, aby ze wzrostem liczności próbki wzrastała dokładność oszacowanego parametru Θ .

Wymaganie to prowadzi do spełnienia (dla każdej liczby $\epsilon > 0$) warunku:

$$\lim_{n \rightarrow \infty} P(|\hat{\Theta}_n - \Theta| < \epsilon) = 1.$$

oznaczającego zbieżność w sensie prawdopodobieństwa (zbieżność stochastyczną) Θ_n do Θ .

Definicja

Estymator Θ_n spełniający powyższy warunek nazywamy **estymatorem zgodnym** parametru Θ .

Estymacja Punktowa (Metoda największej wiarygodności)

Niech rozkład badanej cechy X zależy od k nieznanymi parametrów

$$\theta_1, \dots, \theta_k,$$

które chcemy oszacować na podstawie próbki X_1, \dots, X_n .

Estymacja Punktowa (Metoda największej wiarygodności)

Etap 1.

Najpierw wyznaczamy funkcję wiarygodności próby zgodnie ze wzorami:

$$L(x_1, \dots, x_n; \theta_1, \dots, \theta_r) = \prod_{i=1}^n f(x_i; \theta_1, \dots, \theta_r) \text{ dla rozkładów ciągłych}$$

$$L(x_1, \dots, x_n; \theta_1, \dots, \theta_r) = \prod_{i=1}^n p(x_i; \theta_1, \dots, \theta_r) \text{ dla rozkładów skokowych}$$

gdzie f oznacza funkcję gęstości rozkładu, zaś p funkcję prawdopodobieństwa.

Etap 2.

Wyznaczamy

$$\ln(L(x_1, \dots, x_n; \theta_1, \dots, \theta_r))$$

Estymacja Punktowa (Metoda największej wiarygodności)

Etap 2.

Wyznaczamy

$$\ln(L(x_1, \dots, x_n; \theta_1, \dots, \theta_r))$$

Etap 3.

Wyznaczamy pochodne cząstkowe:

$$\frac{\partial \ln L}{\partial \theta_i} \text{ dla } i = 1, \dots, r.$$

Gdy $L(\theta)$ jest dyskretna nie możemy różniczkować, wyliczamy $\frac{L(n+1)}{L(n)}$.

Wiarygodność wtedy jest maksymalizowana przez najmniejsze n , przy którym ten stosunek jest ≤ 1 .

(Funkcje $\ln L(\theta)$ i $L(\theta)$ osiągają maksimum dla tej samej wartości, a często zamiast $L(\theta)$ wygodniej jest używać logarytmu funkcji wiarygodności.)

Estymacja Punktowa (Metoda największej wiarygodności)

Etap 2.

Wyznaczamy:

$$\ln(L(x_1, \dots, x_n; \theta_1, \dots, \theta_r))$$

Etap 3.

Wyznaczamy pochodne cząstkowe:

$$\frac{\partial \ln L}{\partial \theta_i} \text{ dla } i = 1, \dots, r.$$

Etap 4.

Rozwiązujemy układ równań:

$$\frac{\partial \ln L}{\partial \theta_i} = 0$$

względem θ_i .

Estymacja Punktowa (Metoda największej wiarygodności)

Etap 2.

Wyznaczamy:

$$\ln(L(x_1, \dots, x_n; \theta_1, \dots, \theta_r))$$

Etap 3.

Wyznaczamy pochodne cząstkowe:

$$\frac{\partial \ln L}{\partial \theta_i} \text{ dla } i = 1, \dots, r.$$

Etap 4.

Rozwiązujemy układ równań:

$$\frac{\partial \ln L}{\partial \theta_i} = 0$$

względem θ_i .

Rozwiązania układu stanowią estymatory szukanych parametrów.

Zadanie

Znaleźć estymatory największej wiarygodności parametrów m oraz σ rozkładu normalnego.

Zadanie

Znaleźć estymatory największej wiarygodności parametrów m oraz σ rozkładu normalnego.

Wyznaczamy funkcję wiarygodności:

$$L(X, m, \sigma) = \prod_{i=1}^n f_{m, \sigma}(x_i).$$

Zadanie

Znaleźć estymatory największej wiarygodności parametrów m oraz σ rozkładu normalnego.

Wyznaczamy funkcję wiarygodności:

$$L(X, m, \sigma) = \prod_{i=1}^n f_{m, \sigma}(x_i).$$

Wyznaczamy logarytmiczną funkcję wiarygodności:

$$l = \ln(L(X, m, \sigma)) = \ln\left(\prod_{i=1}^n f_{m, \sigma}(x_i)\right) = \sum_{i=1}^n \ln(f_{m, \sigma}(x_i))$$

Mamy

$$l(X) = \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-m)^2}{2\sigma^2}}\right) = \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) + \sum_{i=1}^n \ln\left(e^{-\frac{(x-m)^2}{2\sigma^2}}\right) =$$

Estymacja Punktowa (Metoda największej wiarygodności)

Mamy

$$\begin{aligned} l(X) &= \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-m)^2}{2\sigma^2}}\right) = \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) + \sum_{i=1}^n \ln\left(e^{-\frac{(x-m)^2}{2\sigma^2}}\right) = \\ &= \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \sum_{i=1}^n \frac{(x-m)^2}{2\sigma^2} = \end{aligned}$$

Mamy

$$\begin{aligned} l(X) &= \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-m)^2}{2\sigma^2}}\right) = \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) + \sum_{i=1}^n \ln\left(e^{-\frac{(x-m)^2}{2\sigma^2}}\right) = \\ &= \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \sum_{i=1}^n \frac{(x-m)^2}{2\sigma^2} = \\ &= \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) + \sum_{i=1}^n \ln\left(\frac{1}{\sigma}\right) - \sum_{i=1}^n \frac{(x-m)^2}{2\sigma^2} = \end{aligned}$$

Mamy

$$\begin{aligned} l(X) &= \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{(x-m)^2}{2\sigma^2}}\right) = \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}\sigma^2}\right) + \sum_{i=1}^n \ln\left(e^{-\frac{(x-m)^2}{2\sigma^2}}\right) = \\ &= \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}\sigma^2}\right) - \sum_{i=1}^n \frac{(x-m)^2}{2\sigma^2} = \\ &= \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) + \sum_{i=1}^n \ln\left(\frac{1}{\sigma}\right) - \sum_{i=1}^n \frac{(x-m)^2}{2\sigma^2} = \\ &= \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) - n \ln(\sigma) - \sum_{i=1}^n \frac{(x-m)^2}{2\sigma^2} \end{aligned}$$

Estymacja Punktowa (Metoda największej wiarygodności)

Policzmy pochodną funkcji wiarygodności po parametrze m i przyrównajmy ją do zera:

$$\frac{\partial}{\partial m} L(X, m, \sigma) = \frac{\partial}{\partial m} \left(\sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) - n \ln(\sigma) - \sum_{i=1}^n \frac{(x_i - m)^2}{2\sigma^2} \right) =$$

Estymacja Punktowa (Metoda największej wiarygodności)

Policzmy pochodną funkcji wiarygodności po parametrze m i przyrównajmy ją do zera:

$$\begin{aligned}\frac{\partial}{\partial m} L(X, m, \sigma) &= \frac{\partial}{\partial m} \left(\sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) - n \ln(\sigma) - \sum_{i=1}^n \frac{(x-m)^2}{2\sigma^2} \right) = \\ &= \sum_{i=1}^n \frac{\partial}{\partial m} \left(-\frac{(x-m)^2}{2\sigma^2} \right) =\end{aligned}$$

Estymacja Punktowa (Metoda największej wiarygodności)

Policzmy pochodną funkcji wiarygodności po parametrze m i przyrównajmy ją do zera:

$$\begin{aligned}\frac{\partial}{\partial m} L(X, m, \sigma) &= \frac{\partial}{\partial m} \left(\sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) - n \ln(\sigma) - \sum_{i=1}^n \frac{(x_i - m)^2}{2\sigma^2} \right) = \\ &= \sum_{i=1}^n \frac{\partial}{\partial m} \left(-\frac{(x_i - m)^2}{2\sigma^2} \right) = \\ &= \sum_{i=1}^n \frac{2(x_i - m)}{2\sigma^2} = \frac{1}{\sigma^2} \left(\sum_{i=1}^n x_i - nm \right) = 0\end{aligned}$$

Estymacja Punktowa (Metoda największej wiarygodności)

Policzmy pochodną funkcji wiarygodności po parametrze m i przyrównajmy ją do zera:

$$\begin{aligned}\frac{\partial}{\partial m} L(X, m, \sigma) &= \frac{\partial}{\partial m} \left(\sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) - n \ln(\sigma) - \sum_{i=1}^n \frac{(x_i - m)^2}{2\sigma^2} \right) = \\ &= \sum_{i=1}^n \frac{\partial}{\partial m} \left(-\frac{(x_i - m)^2}{2\sigma^2} \right) = \\ &= \sum_{i=1}^n \frac{2(x_i - m)}{2\sigma^2} = \frac{1}{\sigma^2} \left(\sum_{i=1}^n x_i - nm \right) = 0\end{aligned}$$

Otrzymujemy równanie:

$$\begin{aligned}\sum_{i=1}^n x_i - nm &= 0, \\ \sum_{i=1}^n x_i &= nm, \\ m &= \frac{1}{n} \sum_{i=1}^n x_i.\end{aligned}$$

Estymacja Punktowa (Metoda największej wiarygodności)

Policzmy pochodną funkcji wiarygodności po parametrze σ i przyrównajmy ją do zera:

$$\frac{\partial}{\partial \sigma} L(X, m, \sigma) = \frac{\partial}{\partial \sigma} \left(\sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) - n \ln(\sigma) - \sum_{i=1}^n \frac{(x-m)^2}{2\sigma^2} \right) =$$

Estymacja Punktowa (Metoda największej wiarygodności)

Policzmy pochodną funkcji wiarygodności po parametrze σ i przyrównajmy ją do zera:

$$\begin{aligned}\frac{\partial}{\partial \sigma} L(X, m_i, \sigma) &= \frac{\partial}{\partial \sigma} \left(\sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) - n \ln(\sigma) - \sum_{i=1}^n \frac{(x-m)^2}{2\sigma^2} \right) = \\ &= \frac{\partial}{\partial \sigma} \left(-n \ln(\sigma) - \sum_{i=1}^n \frac{(x-m)^2}{2\sigma^2} \right) =\end{aligned}$$

Estymacja Punktowa (Metoda największej wiarygodności)

Policzmy pochodną funkcji wiarygodności po parametrze σ i przyrównajmy ją do zera:

$$\begin{aligned}\frac{\partial}{\partial \sigma} L(X, m, \sigma) &= \frac{\partial}{\partial \sigma} \left(\sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) - n \ln(\sigma) - \sum_{i=1}^n \frac{(x_i - m)^2}{2\sigma^2} \right) = \\ &= \frac{\partial}{\partial \sigma} \left(-n \ln(\sigma) - \sum_{i=1}^n \frac{(x_i - m)^2}{2\sigma^2} \right) = \\ &= \frac{-n}{\sigma} - \frac{1}{2\sigma^3} (-2) \sum_{i=1}^n (x_i - \bar{x})^2 = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - \bar{x})^2 = 0.\end{aligned}$$

Estymacja Punktowa (Metoda największej wiarygodności)

Policzmy pochodną funkcji wiarygodności po parametrze σ i przyrównajmy ją do zera:

$$\begin{aligned}\frac{\partial}{\partial \sigma} L(X, m_i, \sigma) &= \frac{\partial}{\partial \sigma} \left(\sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}}\right) - n \ln(\sigma) - \sum_{i=1}^n \frac{(x_i - m)^2}{2\sigma^2} \right) = \\ &= \frac{\partial}{\partial \sigma} \left(-n \ln(\sigma) - \sum_{i=1}^n \frac{(x_i - m)^2}{2\sigma^2} \right) = \\ &= \frac{-n}{\sigma} - \frac{1}{2\sigma^3} (-2) \sum_{i=1}^n (x_i - \bar{x})^2 = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - \bar{x})^2 = 0.\end{aligned}$$

Otrzymujemy równanie:

$$\begin{aligned}-\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - \bar{x})^2 &= 0, \\ \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2 &= n, \\ \sigma^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.\end{aligned}$$

Estymacja Punktowa (Metoda największej wiarygodności)

Zadanie:

https://github.com/przem85/statistic_4/blob/master/D04_Z01_maximum_likelihood_estimation.ipynb